

Predykcja Chorób Serca z Wykorzystaniem Algorytmów Uczenia Maszynowego: Analiza Wrażliwa na Koszty

Raport Analityczny

13 czerwca 2026

1. Wprowadzenie i Opis Danych

Podstawą projektu jest zbiór danych *Cleveland Heart Disease Database*, udostępniony w repozytorium UCI Machine Learning. Dane zostały oryginalnie zebrane przez V.A. Medical Center w Long Beach oraz Cleveland Clinic Foundation pod kierownictwem dr. Roberta Detrano. Głównym celem analizy jest stworzenie modelu klasyfikacyjnego zdolnego do przewidywania obecności choroby serca u pacjentów na podstawie ich wyników badań oraz wywiadu lekarskiego.

1.1 Przygotowanie danych, braki i inżynieria cech

Zbiór pierwotnie zawierał 303 obserwacje. Aby modele uczenia maszynowego działały poprawnie, wdrożono rygorystyczny potok przetwarzania danych:

- **Braki danych:** Surowy zbiór zawierał wybrakowane rekordy oznaczone znakiem zapytania (?). Zostały one skonwertowane do formatu NA, a następnie usunięte z użyciem funkcji `na.omit()`. Dzięki temu zapobiegliśmy zniekształceniu wyników przez sztuczną imputację, opierając się wyłącznie na pewnych wywiadach medycznych.
- **Agregacja celu:** Stadia zaawansowania choroby (1–4) połączono w jedną kategorię, przekształcając problem w klasyfikację binarną (Zdrowy vs Chory).
- **Faktoryzacja:** Cechy katagoryczne zapisane liczbowo (np. rodzaj bólu) przekształcono w typ `factor` z nadaniem tekstowych etykiet, co zabezpiecza model przed niewłaściwym, numerycznym traktowaniem tych zmiennych.
- **Skalowanie danych:** Zmienne ciągłe (np. cholesterol, ciśnienie) posiadają różne jednostki. Aby algorytmy działały stabilnie, w późniejszym etapie zostaną one poddane centrowaniu i skalowaniu.

1.2 Słownik zmiennych wykorzystanych w modelu


Wszystkie zmienne po procesie transformacji zostały scharakteryzowane w tabeli 1.

Kolumna	Typ zmiennej	Opis i oryginalne kodowanie wartości
age	Numeryczna	Wiek pacjenta w latach.
sex	Kategoryczna	Płeć (1 = Mężczyzna, 0 = Kobieta).
cp	Kategoryczna	Rodzaj bólu klatki piersiowej (1=Typowy, 2=Nietypowy, 3=Niesercowy, 4=Bezobjawowy).
trestbps	Numeryczna	Spoczynkowe ciśnienie krwi (mm Hg przy przyjęciu).
chol	Numeryczna	Poziom cholesterolu w surowicy (mg/dl).
fbs	Kategoryczna	Cukier we krwi na czczo (> 120 mg/dl; 1 = Tak, 0 = Nie).
restecg	Kategoryczna	Spoczynkowy wynik EKG (0=Norma, 1=Zmiany ST-T, 2=Hipertrofia).
thalach	Numeryczna	Maksymalne osiągnięte tętno.
exang	Kategoryczna	Dławica piersiowa wywołana wysiłkiem fizycznym (1 = Tak, 0 = Nie).
oldpeak	Numeryczna	Obniżenie odcinka ST wywołane wysiłkiem względem spoczynku.
slope	Kategoryczna	Nachylenie szczytowego wysiłkowego odcinka ST (1=Rosnące, 2=Płaskie, 3=Opadające).
ca	Kategoryczna	Liczba głównych naczyń (0-3) zabarwionych w fluoroskopii.
thal	Kategoryczna	Wynik scyntygrafii talowej (3=Norma, 6=Defekt trwały, 7=Defekt odwracalny).
num	Zmienna celu	Status choroby serca (0 = Zdrowy, 1 = Chory).

Tabela 1: Słownik zmiennych wykorzystanych w analizie i procesie modelowania.

2. Eksploracyjna Analiza Danych (EDA)



Przed przystąpieniem do modelowania przeprowadzono analizę rozkładów oraz korelacji. Na wstępie zweryfikowano proporcję klas zmiennej objaśnianej, co przedstawia Rysunek 1.



Rysunek 1: Rozkład zmiennej celu po binarnej agregacji stadiów choroby.

Wnioski z rozkładu klas: Jak wynika z powyższego wykresu, klasy w badanym zbiorze są naturalnie zbalansowane (prawie równy podział pacjentów zdrowych i chorych). Jest to niezwykle istotne z perspektywy uczenia maszynowego – zwalnia nas to z konieczności stosowania technik sztucznego bilansowania danych i gwarantuje, że klasyfikator nie będzie "faworyzował" klasy większościowej.

Następnie przeanalizowano zmienne kategoryczne w relacji do diagnozy.




Rysunek 2: Procentowe ryzyko choroby w ujęciu podstawowych wywiadów oraz badań specjalistycznych.


Wnioski ze zmiennych kategorycznych: Z zaprezentowanych wykresów słupkowych (Rysunek 2) wylania się obraz kluczowych czynników ryzyka. Najwięcej diagnoz pozytywnych przypada na grupę z bólami "Bezobjawowymi" (cp). Dodatkowo, zaobserwowano, że obecność dławicy wysiłkowej (exang) oraz odwracalny defekt w scyntygrafii (thal) krytycznie zwiększają prawdopodobieństwo wystąpienia choroby.

W kolejnym kroku przyjrano się zmiennym numerycznym.

Analiza rozkładu zmiennych numerycznych Zastosowano jądrowy estymator gęstości (Jądro Radialne/Gausa)



Zmienne numeryczne a diagnoza (Boxploty)




Rysunek 3: Analiza gęstości (Jądro Gaussa) oraz rozstępów dla kluczowych predyktorów ciągłych.

Wnioski ze zmiennych numerycznych: Jak ukazują wykresy pudełkowe (Rysunek 3), tętno maksymalne (*thalach*) jest wyraźnie niższe u pacjentów chorych. Z kolei u tych samych pacjentów wskaźnik obniżenia odcinka ST (*oldpeak*) przyjmuje zauważalnie wyższe wartości, stanowiąc silny biologiczny sygnał patologii serca.

Aby matematycznie potwierdzić powiązania między cechami numerycznymi, wygenerowano macierz korelacji. Zdecydowano się na użycie korelacji Spearmana zamiast Pearsona, ponieważ nie zakłada ona liniowości powiązań ani normalności rozkładów (których nie mamy, np. *oldpeak*), a także jest odporna na wartości odstające występujące naturalnie w danych medycznych (np. ekstremalnie wysoki cholesterol).

Korelacja Spearmana zmiennych numerycznych



Rysunek 4: Korelacja Spearmana dla numerycznych wskaźników klinicznych.

Decyzja o braku redukcji wymiarowości: Mimo zaobserwowania pewnych korelacji negatywnych (np. wiek z tętnem maksymalnym $r = -0.39$, czy obniżenie ST z tętnem $r = -0.44$), zdecydowano się nie usuwać żadnych zmiennych ze zbioru danych. Powody tej decyzji są następujące:

1. Żadna z wartości współczynnika korelacji nie zbliża się do krytycznego progu silnej współliniowości (zwykle $|r| > 0.8$), który mógłby zdestabilizować macierze w modelach matematycznych.
2. Każda ze zmiennych niesie ze sobą udowodnioną, unikalną wartość kliniczną. Usunięcie wieku tylko dlatego, że koreluje z tętnem, pozbawiłoby model fundamentalnej wiedzy demograficznej.
3. Mamy do dyspozycji tylko 13 predyktorów, w tym tylko 5 numerycznych.

3. Metodologia: Preprocessing i Uczenie Wrażliwe na Koszty

3.1 Przeciwdziałanie wyciekowi danych (Data Leakage)

Proces standaryzacji zmiennych ciągłych (skalowanie) to moment, w którym zwróciliśmy szczególną uwagę by nie popełnić tzw. wycieku danych, skalując cały zbiór przed podziałem. W naszym skrypcie parametry (średnią i odchylenie) wyznaczono *wyłącznie* na podzbiórze treningowym, a następnie bezpiecznie zaaplikowano je na zbiór testowy, symulując rzeczywiste zjawisko pojawienia się w placówce nowych, niewidzianych wcześniej pacjentów.

```

1 # 1. Niezależny podział na zbiór treningowy i testowy (70/30)
2 set.seed(123)
3 trainIndex <- createDataPartition(heart_data$num, p = 0.7, list = FALSE)
4 train_data <- heart_data[trainIndex, ]
5 test_data <- heart_data[-trainIndex, ]
6
7 # 2. Parametry standaryzacji wyliczane TYLKO na zbiorze treningowym
8 num_cols <- c("age", "trestbps", "chol", "thalach", "oldpeak")
9 preProcValues <- preProcess(train_data[, num_cols], method = c("center",
10 "scale"))

```

```

10
11 # 3. Aplikacja parametrów na zbiory
12 train_data_std <- train_data
13 test_data_std <- test_data
14 train_data_std[, num_cols] <- predict(preProcValues, train_data[, num_
    cols])
15 test_data_std[, num_cols] <- predict(preProcValues, test_data[, num_cols
    ])

```

Kod 1: Izolacja zbioru testowego i prawidłowe skalowanie

3.2 Analiza wrażliwa na koszty

W diagnostyce kardiologicznej błędy FP (Fałszywy Alarm) i FN (Przeoczenie chorego) niosą zupełnie inny ciężar gatunkowy. Wdrożono asymetryczną macierz kosztów, gdzie **waga błędu FN wynosi 3, a waga FP wynosi 1**.

Uzasadnienie wagi 3: Odesłanie chorego pacjenta do domu niesie ze sobą bezpośrednie ryzyko ciężkiego uszczerbku na zdrowiu lub zgonu (ogromny koszt). Skierowanie zdrowego pacjenta na dalsze badania wygeneruje jedynie dodatkowe koszty (finansowe, stres) dla NFZ/szpitala. Koszt FN nie może być jednak ustawiony jako nieskończoność (np. waga 100), ponieważ doprowadziłoby to do sparaliżowania placówki zdrowia – każdemu pacjentowi zlecane byłyby najdroższe badania inwazyjne, niezależnie od objawów. Waga równa 3 uznawana jest za optymalny kompromis kliniczno-biznesowy.

Aby odzwierciedlić tę logikę, próg odcięcia decyzyjnego (p^*) w modelach probabilistycznych został zredukowany:

$$p^* = \frac{C_{FP}}{C_{FP} + C_{FN}} = \frac{1}{1 + 3} = 0.25 \quad (1)$$

```

1 # A) Drzewo decyzyjne - macierz strat (FN = 3, FP = 1)
2 macierz_strat <- matrix(c(0, 1, 3, 0), byrow = TRUE, nrow = 2)
3 model_tree_big <- rpart(num ~ ., data = train_data_std, method = "class"
    ,
4                               parms = list(loss = macierz_strat),
5                               control = rpart.control(cp = 0.001))
6
7 # B) Regresja Logistyczna - obniżenie progu decyzyjnego do 25%
8 prob_log_test <- predict(model_log, test_data_std, type = "response")
9 pred_log_test <- factor(ifelse(prob_log_test > 0.25, "Chory", "Zdrowy"),
10                          levels = c("Zdrowy", "Chory"))

```

Kod 2: Uczenie wrażliwe na koszty w kodzie

4. Architektura i Interpretacja Modeli

W badaniu zestawiono trzy algorytmy klasyfikacyjne. Skupiono się nie tylko na ich mocy predykcyjnej, ale przede wszystkim na głębokiej interpretacji klinicznej uzyskanych reguł matematycznych.

4.1 Regresja Logistyczna

Definicja matematyczna: Regresja logistyczna to model parametryczny należący do rodziny uogólnionych modeli liniowych (GLM). Służy do szacowania prawdopodobieństwa wystąpienia

zdarzenia binarnego (w naszym przypadku: klasa "Chory"). Używa ona funkcji logistycznej, która mapuje liniową kombinację cech do przedziału (0, 1):

$$P(Y = 1 | X) = \frac{1}{1 + e^{-(\beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_k X_k)}} \quad (2)$$

W modelu tym poszukujemy optymalnych współczynników β , które maksymalizują funkcję wiarygodności (Maximum Likelihood Estimation).

Interpretacja statystyczna (summary(model_log)): Z analizy wskaźników dopasowania wynika, że model cechuje się wysoką jakością (spadek *Residual deviance* do 134.60 w stosunku do *Null deviance* równego 287.12). Przeprowadzony test Walda ($Pr(> |z|)$) wyodrębnił kluczowe statystycznie predyktory ($p - value < 0.05$):

- **Bezobjawowy ból w klatce piersiowej (cpBezobjawowy):** Posiada potężny, dodatni współczynnik $\beta \approx 2.9475$ ($p = 0.0015$). Oznacza to, że brak klasycznego bólu, u pacjentów posiadających inne niepokojące symptomy, jest wysoce alarmujący. Jest to zjawisko znane w kardiologii, często zwiastujące najgroźniejsze stany.
- **Liczba zabarwionych naczyń (ca):** Algorytm automatycznie zastosował kodowanie zero-jedynkowe dla tej zmiennej kategorycznej, przyjmując stan **ca0** (brak zablokowanych naczyń) jako grupę referencyjną. Współczynniki dla pozostałych poziomów, czyli **ca1** ($\beta \approx 2.18$), **ca2** ($\beta \approx 2.56$) oraz **ca3** ($\beta \approx 2.44$), są silnie dodatnie i statystycznie bardzo istotne ($p < 0.01$). Oznacza to drastyczny wzrost ryzyka wystąpienia choroby u pacjentów z jakimkolwiek zablokowanym naczyniem.
- **Płeć Męska (sexMęczyzna):** Współczynnik dodatni $\beta \approx 1.59$ wskazuje na wyższe ryzyko bazowe u mężczyzn w badanej próbie.
- **Ciężnienie tętnicze (trestbps):** Mniejszy, ale wciąż istotny współczynnik dodatni $\beta \approx 0.49$.

Co ciekawe, zmienne takie jak poziom cholesterolu (**chol**) czy wiek (**age**) nie wykazały liniowej istotności statystycznej w obecności pozostałych predyktorów, co potwierdza, że w zaawansowanej diagnostyce sam wiek nie jest wyrokiem, a liczy się fizjologiczny stan narządów.

4.2 Naiwny Klasyfikator Bayesa

Definicja matematyczna: Naiwny Bayes to algorytm probabilistyczny zakorzeniony w klasycznym twierdzeniu Bayesa. Określa on prawdopodobieństwo a’posteriori przynależności do danej klasy. Człon "naiwny" odnosi się do silnego, choć często nierealistycznego w przyrodzie, założenia o całkowitej warunkowej niezależności cech:

$$P(Y | X_1, \dots, X_n) = \frac{P(Y) \prod_{i=1}^n P(X_i | Y)}{P(X_1, \dots, X_n)} \quad (3)$$

Interpretacja statystyczna (print(model_nb)): Z wygenerowanego podsumowania modelu jasno wynika profil pacjentów. Prawdopodobieństwo a’priori ($P(Y)$) dla zbioru treningowego wynosiło 53.8% dla klasy "Zdrowy" oraz 46.2% dla "Chory". Analiza tablic prawdopodobieństw warunkowych ($P(X_i|Y)$) kapitalnie obrazuje medyczny sens algorytmu:

- **Typ bólu (cp):** Aż 77.08% pacjentów chorych prezentowało ból typu "Bezobjawowy", podczas gdy u zdrowych odsetek ten wynosił tylko 23.21%.
- **Płeć (sex):** Klasa chorych składa się w 81.25% z mężczyzn, natomiast klasa zdrowych jest znacznie bardziej zbalansowana (53.57% mężczyzn do 46.43% kobiet).

- **Nachylenie ST (slope):** U pacjentów chorych dominuje płaskie nachylenie odcinka ST (67.7%), z kolei u pacjentów zdrowych przeważa nachylenie w górę (61.6%).
- **Zmienne ciągłe:** Ponieważ dane były standaryzowane, średnie warunkowe (np. dla `thalach`) wynoszą -0.419 dla chorych i 0.359 dla zdrowych, co matematycznie dowodzi (zgodnie z EDA), że chorzy mają zauważalnie niższe tętno wysiłkowe.

Dzięki takiemu rozkładowi, Naive Bayes płynnie wyłapuje poszczególne "flagi alarmowe", mnożąc je przez siebie i generując ostateczną diagnozę probabilistyczną.


4.3 Drzewo Decyzyjne

Definicja matematyczna: Klasyfikator nieliniowy i nieparametryczny. Wykorzystuje rekurencyjny podział przestrzeni cech. Algorytm w każdym węźle szuka zmiennej i jej punktu odcięcia, który maksymalnie separuje klasy, minimalizując tzw. wskaźnik zanieczyszczenia Giniego:

$$Gini = 1 - \sum_{i=1}^c (p_i)^2 \quad (4)$$

Interpretacja struktury drzewa: Aby uniknąć zjawiska zapamiętania szumu informacyjnego z danych uczących, surowe drzewo poddano iteracyjnemu procesowi przycinania (*Pruning*). Wykorzystano do tego parametr złożoności (`cp` - *Complexity Parameter*), wybierając taką jego wartość, która minimalizowała błąd w walidacji krzyżowej (`xerror`).

Zoptymalizowane drzewo działa niemal identycznie jak lekarski algorytm triażowy. Głównym węzłem decyzyjnym o najwyższym zysku informacyjnym okazał się rodzaj bólu w klatce piersiowej (`cp`). U pacjentów zaklasyfikowanych jako "Bezobjawowi", model natychmiast poszukuje weryfikacji w zaawansowanych badaniach obrazowych (wykorzystując wskaźnik niedotlenienia `oldpeak` oraz defekt w scyntygrafii `thal`), co perfekcyjnie wręcz naśladuje logikę podejmowania decyzji przez lekarza diagnostę.



Rysunek 5: Wizualizacja zoptymalizowanego drzewa decyzyjnego po zastosowaniu procesu Pruningu.

5. Walidacja i Ostateczne Wyniki

Proces oceny modeli to najważniejszy element metodologii. Podzielono go na trzy rygorystyczne etapy. Z uwagi na wdrożoną we wstępie asymetrię kosztów, której zadaniem jest ratowanie życia poprzez drastyczne unikanie błędów *False Negative*, główną i decydującą miarą oceny algorytmów była **Czułość (Sensitivity)**.

5.1 Etap 1: Analiza na zbiorze treningowym (Ryzyko przeuczenia)

Ocena na zbiorze, na którym modele się uczyły (czyli weryfikacja "własnych odpowiedzi na znane pytania"), jest zjawiskiem czysto poglądowym. Stanowi ona punkt odniesienia do detekcji zjawiska *overfittingu* w późniejszych fazach.

- **Regresja Logistyczna:** Czułość **93.75%**
- **Drzewo Decyzyjne:** Czułość **90.62%**
- **Naiwny Bayes:** Czułość **86.46%**

Interpretacja Etapu 1: Wyniki są optymistyczne. Regresja Logistyczna osiągnęła imponujący pułap niemal 94%, znakomicie separując klasy pacjentów chorych, co dowodzi dobrego dopasowania hiperpłaszczyzny do danych wejściowych. Taki wysoki wynik wygenerował jednak konieczność sprawdzenia modelu pod kątem potencjalnego przeuczenia.

5.2 Etap 2: Walidacja Krzyżowa (Sprawdzian stabilności w 10-Fold CV)

Aby zweryfikować podejrzenia z Etapu 1 i zniwelować wpływ szczęśliwego doboru próbek, poddano modele *10-krotnej walidacji krzyżowej*. Proces ten polega na podzieleniu zbioru treningowego na 10 równych podzbiorów (tzw. *folds*). W każdej z dziesięciu iteracji model uczy się na dziewięciu podziorach, a testowany jest na dziesiątym, uprzednio odłożonym. Uśrednienie wyników pokazuje nam realną stabilność algorytmu w obliczu wariancji danych.

- **Naiwny Bayes:** Czułość **86.44%** (*Spadek o zaledwie 0.02 p.p.*)
- **Regresja Logistyczna:** Czułość **85.44%** (*Spadek o 8.31 p.p.*)
- **Drzewo Decyzyjne:** Czułość **75.89%** (*Spadek aż o 14.73 p.p.*)

Interpretacja CV: Zgodnie z przewidywaniami dla modeli nieparametrycznych, Drzewo Decyzyjne ukazało swoją największą wadę konstrukcyjną – skrajną niestabilność. Zmiana kilku obserwacji w poszczególnych pętach treningowych doprowadziła do drastycznego spadku czułości do nieakceptowalnego w medycynie poziomu 75.89%. Z kolei model Naiwnego Bayesa, oparty na sztywnych twierdzeniach probabilistycznych, okazał się niezwykle odporny na szum (niemal zerowy spadek). Regresja Logistyczna zanotowała naturalną i akceptowalną korektę w dół.

5.3 Etap 3: Ostateczna ewaluacja na zbiorze testowym

Po potwierdzeniu zachowań modeli, poddano je próbie ostatecznej na fizycznie odseparowanym zbiorze testowym (stanowiącym 30% wszystkich danych), którego żaden algorytm wcześniej "nie widział".

- **Regresja Logistyczna:** Czułość **90.24%**, Swoistość **75.00%**, Dokładność **82.02%**
- **Drzewo Decyzyjne:** Czułość **90.24%**, Swoistość **58.33%**, Dokładność **73.03%**
- **Naiwny Bayes:** Czułość **85.37%**, Swoistość **87.50%**, Dokładność **86.52%**

Interpretacja generalizacji: Zbiór testowy dowiódł potęgi modeli parametrycznych. Regresja Logistyczna wygenerowała tzw. "odbicie" z walidacji krzyżowej, świetnie generalizując reguły i osiągając rewelacyjny wynik 90.24% czułości na nowych pacjentach. Drzewo Decyzyjne zdołało wyrównać ten wynik czułości, co sugeruje optymalny układ rekordów w zbiorze testowym, jednak uwydatniła się w nim krytyczna słabość w obszarze Swoistości.

5.4 Ostateczny werdykt i wnioski wdrożeniowe

Biorąc pod uwagę całe spektrum zebranych wyników matematycznych i przekładając je na realia funkcjonowania systemu opieki zdrowotnej, sformułowano następujące wnioski:

Odrzucenie Drzewa Decyzyjnego: Mimo wysokiej czułości testowej, model ten cechuje się niedopuszczalnie niską swoistością (58.33%). Przekładając to na liczby: ponad 40% pacjentów w pełni zdrowych otrzymałoby diagnozę "Chory" (błąd *False Positive*). W rzeczywistości szpitalnej doprowadziłoby to do paraliżu oddziałów poprzez masowe, błędne kierowanie pacjentów na drogę i inwazyjne zabiegi, np. koronarografię. Jego silna niestabilność w kroswalidacji ostatecznie go dyskwalifikuje.

Odrzucenie Naiwnego Bayesa: Algorytm ten stanowi klasyczną w Data Science pułapkę metryki *Accuracy*. Mimo świetnej ogólnej dokładności na poziomie 86.52% i doskonałej swoistości (87.50%), jego kluczowa czułość wyniosła zaledwie 85.37%. Z medycznego punktu widzenia oznacza to zbagatelizowanie objawów i odesłanie do domu blisko 15% pacjentów z faktyczną chorobą serca. W kontekście polityki zminimalizowania zgonów, jest to wynik zbyt niski.

REKOMENDACJA WDROŻENIOWA - Regresja Logistyczna: Zdecydowanym zwycięzcą eksperymentu i jedynym modelem rekomendowanym do operacyjnego wdrożenia w roli asystenta diagnostycznego jest Regresja Logistyczna.

1. Algorytm bezbłędnie zaadaptował obniżony z racji asymetrii kosztów próg decyzyjny ($p^* = 0.25$), osiągając znakomitą czułość testową rzędu **90.24%**. Oznacza to uratowanie życia przytłaczającej większości zagrożonych pacjentów.
2. Równocześnie, w przeciwieństwie do drzewa decyzyjnego, model ten utrzymał zbalansowaną, wysoką Swoistość na poziomie **75.00%**. Stanowi to perfekcyjny kompromis finansowy – placówka medyczna nie zostanie obciążona drastycznymi kosztami fałszywych alarmów.
3. Model ten, z racji swojego parametrycznego charakteru (GLM), pozwala lekarzom łatwo odczytać logikę decyzji (współczynniki β), unikając odrzucenia technologii ze względu na efekt "czarnej skrzynki".